

# AAKR을 이용한 원자력 발전소 고장 패턴 추출에 관한 연구

박기범<sup>†\*</sup>·안홍민<sup>\*</sup>·강성기<sup>\*</sup>·채장범<sup>\*\*</sup>

## Study on the Extraction of Nuclear Power Plant Failure Patterns using AAKR

Kibeom Park<sup>†\*</sup>, Hongmin Ahn<sup>\*</sup>, Seongki Kang<sup>\*</sup> and Jangbom Chai<sup>\*\*</sup>

(Received 2 January 2017, Revised 30 March 2017, Accepted 3 April 2017)

### ABSTRACT

In this paper, we investigate the feasibility of a strategy of failure detection and identification. The point of proposed strategy includes a pattern extraction approach for failure identification using Auto-Associative Kernel Regression (AAKR). We consider a simulation data concerning 605 signals of a Generic Pressurized Water Reactor(GPWR). In the application, the reconstructions are provided by a set of AAKR models, whose input signals have been selected by Correlation Analysis(CA) for the identification of the groups. The failure pattern is extracted by analyzing the residuals of observations and reconstructions. We present the possibility of extraction of patterns for six failure.

**Key Words :** Simulator(시뮬레이터), Auto-Associative Kernel Regression(AAKR), Correlation Analysis(상관분석), Pattern Extraction(패턴추출)

### 기호설명

APR = Advance Power Reactor  
GPWR = Generic Pressurized Water Reactor  
PORV = Pressure Operated Relief Valve  
BOP = Balance of Plant  
RCS = Reactor Coolant System

### 1. 서 론

원자력발전소(이하 원전)는 안전이 핵심이 되는 시설로서 주요 기능의 수행만큼이나 철저한 안전 관리가 요구된다. 게다가 높은 원전 이용률(Capacity

Factor)과 함께 더 효율적인 운전비용에 대한 요구도 증가하고 있는 추세이다. 이러한 요구에 맞추어 원전 이용률과 안전을 함께 개선하기 위해서는 원전의 잠재적 고장들을 예방하기 위한 조치가 필요하다. 원전의 여러 설비, 계측기 및 공정에서는 다양한 결합 및 고장이 발생할 수 있으며, 발전소의 성능에 상당한 영향을 줄 수 있다.

대표적인 예로는 증기발생기 유량 센서의 드리프트가 3% 정도의 원자로 출력 감소를 가져오는 것이 있다.<sup>(1)</sup>

본 논문에서는 원전에서 발생하는 여러 유형의 고장을 조기에 검출 및 식별하기 위한 방법을 연구하였다. 특히 취득이 어려운 현장의 다양한 고장 데이터를 원전 시뮬레이터(Simulator)를 이용해 간접적으로 취득하여 적용함으로써 실용 가능성을 확인하였다. 여기서 고장 식별을 위한 패턴을 도출하기 위해 데이터 기반의 AAKR(Auto-Associative Kernel Regression) 방법을 적용하였다. 상관분석(Correlation Analysis)을

† 책임저자, 회원, ㈜엠앤디

kbpark@e-mnd.com

TEL: (031)303-8661 FAX: (031)303-8664

\* (주)엠앤디

\*\* 아주대학교 기계공학부

통해 그룹화(Grouping)한 신호들과 AAKR 모델을 이용하여 추정치를 계산하였고, 각 고장의 패턴(Pattern)은 모델 추정치와 측정치 사이의 잔차(Residual) 분석을 통해 도출하였다.

## 2. 본 론

### 2.1 원전 데이터

#### 2.1.1 시뮬레이터 개요

원전 신호의 변화를 분석하기 위해 WSC(Western Service Corp.)가 개발한 GPWR(Generic Pressurized Water Reactor) 원전용 시뮬레이터를 사용하였다. GPWR의 원자로는 2개의 루프를 가지고 있으며 4개의 원자로 냉각재펌프와 2개의 증기발생기로 구성되어 있다. 터빈은 1개의 고압터빈과 3개의 저압터빈, 4개의 습분분리재열기로 구성되어 있다. BOP 시스템으로는 복수펌프, 저압가열기, 고압가열기, 주급수펌프, 보조급수펌프 등이 있으며 시뮬레이터의 GPWR 사양은 Table 1에 기술하였다.<sup>(2)</sup>

GPWR 시뮬레이터는 총 8개의 시스템과 72개의 서브시스템으로 구성되어 있으며 각 요소들을 클릭하여 해당 시스템/서브시스템 화면으로 넘어갈 수 있다. Fig. 1은 시뮬레이터의 계통 전체를 도식화한 OVERVIEW PAGE화면이다. 그림에서 보는 바와 같이 원자로, 증기발생기, 터빈, 복수기 등 주요 기기들이

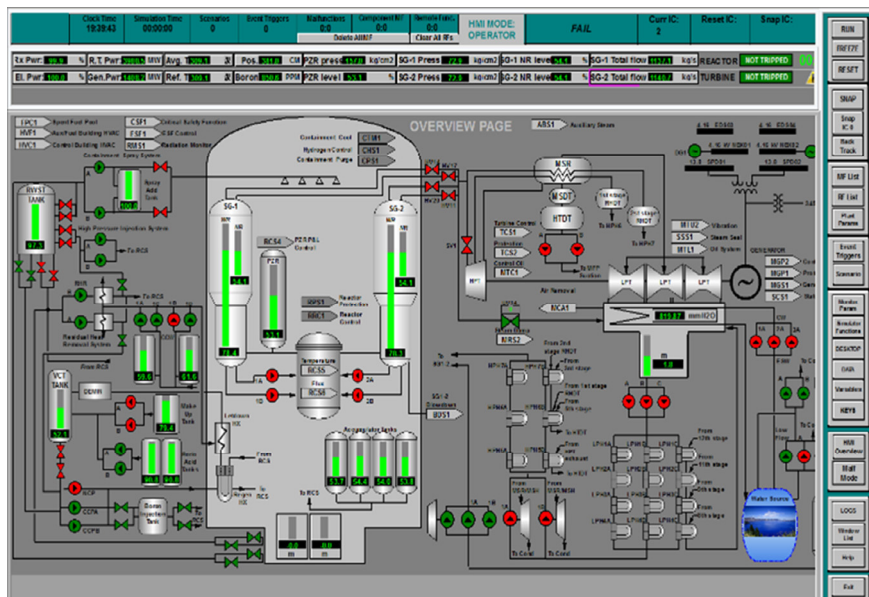
**Table 1.** GPWR Simulator Specification

	Plant Item	Plant Description
Reactor	Configuration	2 loops 4 Reactor Coolant Pumps 2 Steam Generators
	Reactor core power	3983 MW
Turbine	Configuration	1 HP and 3 LP turbine
	Generator power Moisture separator reheaters	1400 MW 4 two stage MSRs
BOP Systems	Condensate pump	3 ea
	Low pressure heaters	3 x LPH#1~#4
	Main feed water pumps	2 turbine driven pumps
	High pressure heaters	2 x HPH#5~7
	Auxiliary feed pump	2 centrifugal pumps 1 turbine driven pump

표시되어 있으며 상부에는 원자로 출력, 터빈출력, 증기발생기 압력, 수위 등 주요 상태 값이 표시되어 있다. 그 밖에 압력, 유량, 온도, 수위와 같은 상태 정보 및 밸브 위치, RPM 등 기기 대한 정보를 확인할 수 있다.

#### 2.1.2 고장 시뮬레이션

원전 전문가의 자문을 통해 발전소 운용 중 발생했던 고장 6종류를 선별하여 시나리오를 정의하고, 이에 따라 시뮬레이션을 수행하여 정상상태 데이터와 고장 데이터를 생성하였다. 본 논문에서는



**Fig. 1** HMI : OVERVIEW PAGE

이 데이터들을 원전에서 측정한 측정치로 가정하였다. 각 고장의 종류는 Table 2와 같다. 각 고장에 대한 설명은 아래와 같다.

1) 주급수펌프 재순환밸브 고장(MFW Pump Recirculation Valve Fail)은 주급수펌프 A측 재순환밸브 고장 열림(25%)으로 인해 증기발생기로 급수 공급이 감소하여 증기발생기 2대 모두 수위가 감소한다. 증기발생기 수위제어계통의 자동 운전으로 인해 주급수펌프 속도 등이 증가하고 증기발생기 수위를 회복시킨다.

2) 가압기 수위 전송기 고장(PRZ Level Master Controller Fail)은 수위 주제어기로 신호를 공급, 수위가 높음을 감지하여 수위를 낮추려는 자동동작이 발생(CVCS 충전유량 증가), 실제 가압기 수위는 서서히 감소한다. 그리고 가압기 Back up Heaters all on 등의 추가적인 현상이 발생한다.

3) 원자로 냉각재계통 고온관 누설 고장(RCS Loop1 H/L Leak)은 RCS 고온관에서 미세한 누설이 발생하여 격납건물 내부의 방사선준위, 습도 등이 증가하고 가압기 수위는 미세 감소 후 자동 운전계통으로 인해 정상으로 회복된다.

4) 복수기 진공도 저하 고장(Loss of Condenser Vacuum)은 높은 진공이 형성된 복수기에 복수계통의 밸브 스템에서 임의의 개구부가 발생하여 진공도가 나빠지면서 복수기 전체에 영향을 미쳐 결국은 열효율 감소로 인해 터빈/발전기 출력이 감소한다. 진공도 악화가 지속, 자동 터빈정지 설정치까지 도달 시에는 터빈정지까지 발생할 수 있다.

5) 가압기 PORV 내부누설 고장(PRZ PORV Internal Leakage)의 경우 가압기 PORV의 극미세 내부누설로 PORV 후단 온도가 증가하고 경보가 발생, 그 후단의 PRT(가압기압력방출탱크)의 온도/압력/수위가 증가한다. 또한, 밸브의 미세누설을 감지하는 음향누설감시계통(Acoustic Leak Monitoring Sys.)에 누설감지 경보가 발생한다.

6) 증기발생기 세관누설고장(Steam Generator Tube Leak)의 경우 세관 누설로 인해 방사능이 함유된 원자로냉각재가 2차측으로 유입, 주증기/복수/급수/증기발생기 취출수에 방사선농도가 증가한다. 하지만, RCS의 극미세 누설로 인해 가압기 수위 등의 변화는 미약하다.

**Table 2.** Malfunction List

No.	List
1	MFW Pump Recirculation Valve Fail
2	PRZ Level Master Controller Fail
3	RCS Loop1 H/L Leak
4	Loss of Condenser Vacuum
5	PRZ PORV Internal Leakage
6	Steam Generator Tube Leak

## 2.2 데이터 기반 모델

### 2.2.1 AAKR(Auto-Associative Kernel Regression)

데이터 세트로부터 최대한 가장 정확히 추정할 수 있는 회귀식을 생성하는 방법에는 일반적으로 모수적(Parametric Method)과 비모수적 방법(Non-parametric Method)이라는 두 가지 방법이 있다. 분석대상 데이터가 정규분포를 구성한다는 전제하에 근사 값을 추정하는 모수적 방법인 선형회귀(Linear Regression)이나 다항회귀(Polynomial Regression)와 달리, 사전에 아무런 가정을 하지 않고 회귀식을 추정하는 비모수적 방법인 커널회귀(Kernel Regression)가 있다. 과거 표본 값의 가중평균을 계산함으로써 회귀식을 추정하는 커널회귀 중, AAKR을 이용하면 회귀식을 추정하는 경험 모델을 만들 수 있다.<sup>(3-6)</sup>

기본적으로 AAKR은 정상운전 동안 수집된 과거의 측정 변수  $X^{nc}$ 와 현재 측정된 변수  $X$ 의 비교를 통해 정상상태에서 예상되는 변수  $\hat{X}$ 를 추정하는 것이다.  $X^{nc}$ 는 과거의 데이터로 구성된 행렬로서 메모리 벡터라고 하고  $J$ 개의 변수와  $N$ 개의 데이터로 구성된  $X^{nc}$ 는 다음과 같이  $J \times N$  행렬이 된다.

$$X^{nc}(j, k) = \begin{bmatrix} x_{1,1} & x_{1,2} & \dots & x_{1,J} \\ x_{2,1} & x_{2,2} & \dots & x_{2,J} \\ \dots & \dots & \dots & \dots \\ x_{N,1} & x_{N,2} & \dots & x_{N,J} \end{bmatrix}, (j = 1, \dots, J, k = 1, \dots, N)$$

모델에 실시간으로 측정되는 변수들로 구성된 벡터  $X = [x_1, x_2, \dots, x_J]$ 가 입력되면 아래 식으로  $X^{nc}$ 를 구성하는 각 벡터와의 유클리드 거리(Euclidean Distance)  $d(k)$ 를 구할 수 있다.

$$d(k) = \sqrt{\sum_{j=1}^J (X(j) - X^{nc}(k, j))^2}$$

이 때 계산된 거리  $d(k)$ 를 비교하여 유사성을 평

가하고 이에 따라 가중치  $\omega(k)$ 를 부여한다. 거리  $d(k)$ 에 대한 가중치  $\omega(k)$ 의 계산은 가우시안 커널 함수(Gaussian Kernel Function)를 사용하여 다음 식으로 구할 수 있다.

$$\omega(k) = \frac{1}{\sqrt{2\pi}h} e^{-\frac{d^2(k)}{2h^2}}$$

여기서  $h$ 는 커널함수의 형태를 조절하는 커널 폭(Kernel Bandwidth) 파라미터로서,  $h$ 에 따라 거리에 따른 가중치  $\omega(k)$ 가 결정된다.

최종적으로 추정치  $\hat{X}$ 은 가중치  $\omega(k)$ 와 메모리 벡터  $X^{nc}$ 가 결합한 가중평균으로 다음과 같이 쓸 수 있다.

$$\hat{X}(j) = \frac{\sum_{k=1}^N \omega(k) X^{nc}(k,j)}{\sum_{k=1}^N \omega(k)}$$

AAKR 모델은 입력 데이터의 선별 및 그룹화와 커널폭( $h$ ) 조절에 의해 최적화 될 수 있다.<sup>(3,5,7)</sup>

## 2.2.2 신호 그룹화

AKR 방법으로 신호를 추정하는 방법은 크게 전체 변수를 모두 이용하는 방법과 그룹화를 통해 상태를 추정하는 방법으로 나뉜다. 그룹화를 통한 방법은 유용한 신호들만 이용하는 방법으로서 분류 기준으로는 센서의 물리적, 기능적 동질성(Homogeneity), 신호 간 상관관계 등이 있다.<sup>(8)</sup>




Fig. 2 Grouping by CA(Correlation Analysis)

AAKR 적용에 앞서 605개의 변수로 이루어진 원전 시뮬레이션 데이터의 상관분석(Correlation Analysis)을 수행하고 상관계수가 0.9 이상인 신호들을 그룹화 하였다. 또한 추정치를 계산하기 위해 Fig. 2와 같이 각 그룹에 대한 AAKR 모델을 만들고 각 모델에 해당하는 신호들로 벡터를 구성해 입력하였다.

## 2.3 모델 검증 및 임계치 설정

### 2.3.1 모델 검증

모델의 정확도를 평가하기 위해 정상상태 데이터 중 50%를 학습 데이터로 이용하여 메모리 벡터를 구성하고 나머지 50%를 검증 데이터 세트로 하여 AAKR 모델을 검증하였다.

모델의 정확도는 일반적으로 정상상태 하의 측정치와 추정치 사이의 평균 제곱 편차(Mean Squared Error)로 정의하며 다음 식으로 계산할 수 있다.

$$MSE(j) = \frac{\sum_{k=1}^N (\hat{X}(k,j) - X(k,j))^2}{N}$$

Fig. 3은 정상상태에서 측정된 605개의 변수와 모델 추정치 사이의 평균 제곱 편차를 정상 신호의 분산( $\sigma$ )으로 나누어 정규화(Normalization)한 것이다. 그림에서 각 변수에 대한 편차가 표준편차의 최대 1.6배 이내에 있음을 확인할 수 있다. 이것은 모델 추정 결과가 각 변수가 갖는 고유의 불확도(Uncertainty) 범위를 벗어나지 않는 것을 의미한다.




Fig. 3 Normalized error of normal condition

### 2.3.2 임계치 설정

일반적으로 AAKR의 사용 목적은 특정 시간에서 전체 또는 특정 변수의 추정치를 제공하는 것이지만 이상 상태를 식별하기 위한 목적으로 임계치를 설정하여 측정치와 추정치 사이의 잔차를 감시할 수도 있다. 이 때 임계치는 보통 검증 데이터 세트를 통해 산출된 평균 제공근 편차를 기준으로 설정하는데, 검증 데이터 세트의 잔차를 정규 분포라고 하면 평균은 0이 되고 분산은 평균 제공 편차와 같아지기 때문에 평균 제공근 편차의 4배를 임계치로 설정함으로써 정상 조건에서 잔차가 공정 노이즈(Process Noise)를 초과하는 것을 감지할 수 있고 오경보(False Alarm)의 발생 빈도를 줄일 수 있다.<sup>(9)</sup> 이를 기준으로 임계치를 설정하고 측정치와 추정치 사이의 잔차  $r(k,j) = \hat{X}(k,j) - X(k,j)$ 가  $r(k,j) > threshold$ 인 변수를 검출하여 이상 변수(Abnormal Variable)로 판정하였다. Fig. 4는 605개 변수에 대한 임계치를 나타낸 것이다.

$$threshold = 4\sqrt{MSE(j)}$$




Fig. 4 The thresholds for state variables

## 2.4 고장 데이터 분석 및 패턴 추출

### 2.4.1 이상 변수

Table 2의 고장에 대해서 임계치를 벗어나는 이상 변수를 검출하기 위해 AAKR 모델을 이용해 잔차를 구하고 임계치와 비교하여 이상 변수의 조합을 도출하였다.

Fig. 5~10은 각 고장 데이터의 잔차와 임계치 및 이상 변수를 나타낸 것이다. 각 변수에 대한 임계치는

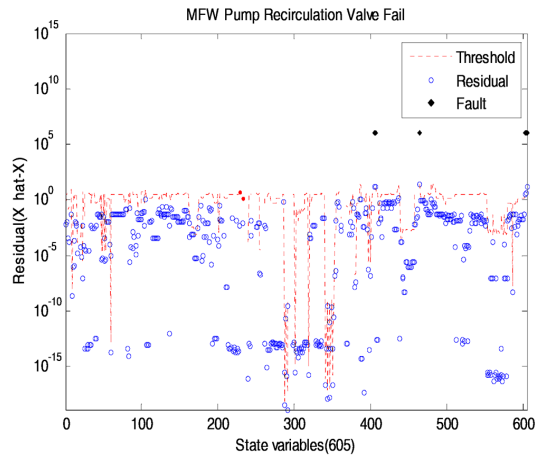


Fig. 5 Residuals with the thresholds for malfunction 1

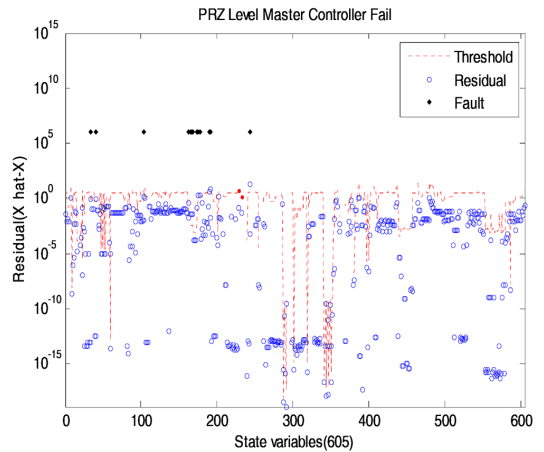


Fig. 6 Residuals with the thresholds for malfunction 2

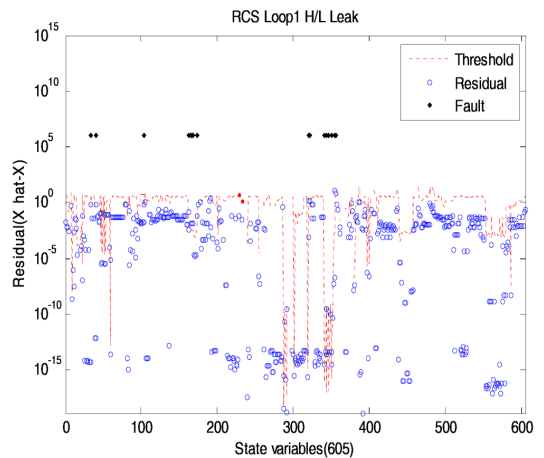


Fig. 7 Residuals with the thresholds for malfunction 3

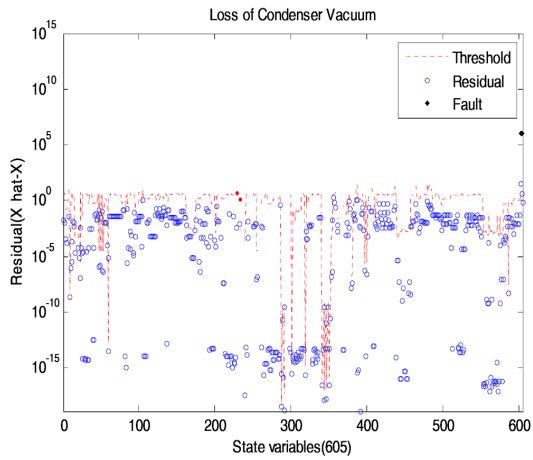


Fig. 8 Residuals with the thresholds for malfunction 4

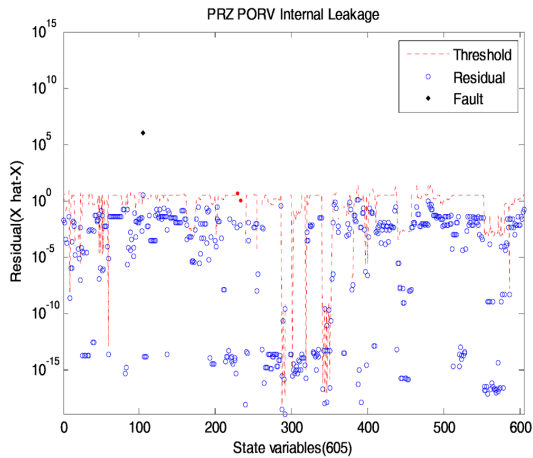


Fig. 9 Residuals with the thresholds for malfunction 5

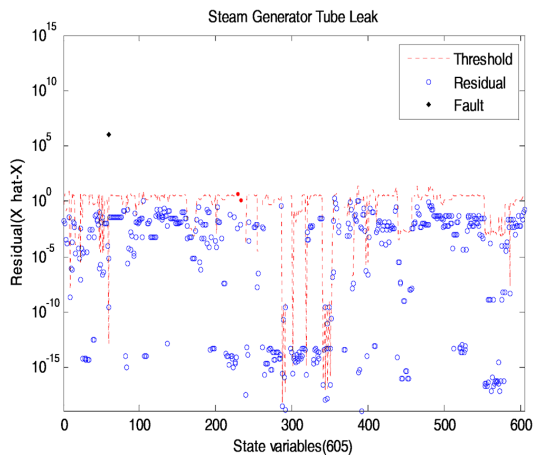


Fig. 10 Residuals with the thresholds for malfunction 6

점선으로 표시하였고 측정치와 추정치 사이의 잔차는 ○으로 표시하였다. 잔차가 임계치를 넘었을 경우에는 해당하는 이상 변수에 ◆를 추가하였다.

데이터 분석 결과에 따르면 6개의 고장 모두 특정 변수의 잔차가 임계치 이상으로 크게 증가하는 것으로 나타났다. 그 중 1, 2, 3, 4번 고장에서는 이상 변수가 여러 변수의 조합으로 나타났으며 5, 6번 고장에서는 1개의 변수만 유일하게 이상으로 판정되었다.

## 2.4.2 이상 시점

Fig. 11~14는 이상 변수가 1개 이상인 1, 2, 3, 4번 고장에 대해서 고장의 영향력이 전파되는 특성을 확인하기 위해 이상 변수들이 임계치를 넘어서는 시점을

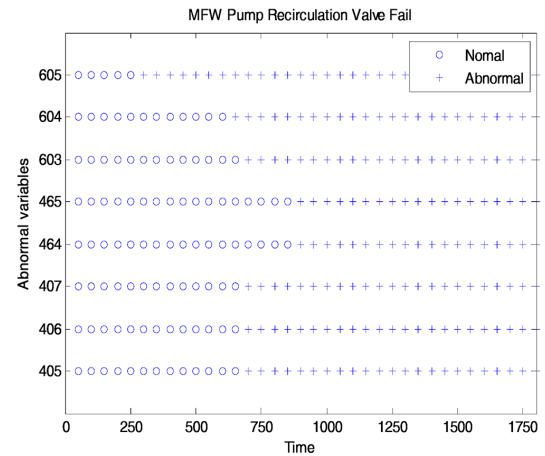


Fig. 11 Time dependent signal status results for malfunction 1




Fig. 12 Time dependent signal status results for malfunction 2

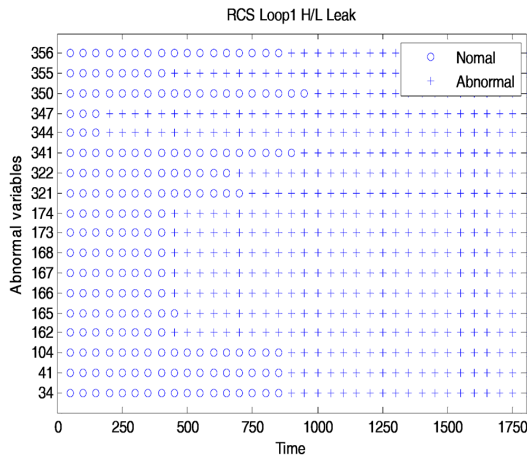


Fig. 13 Time dependent signal status results for malfunction 3

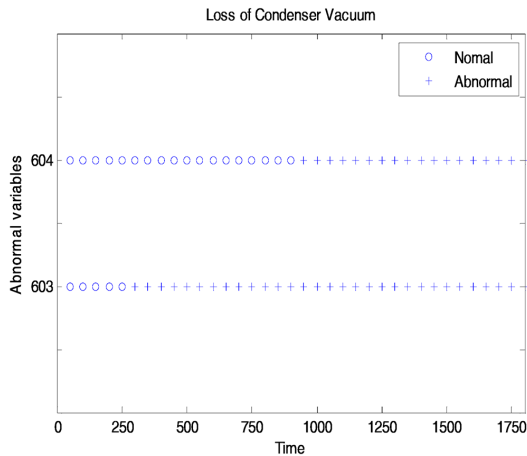


Fig. 14 Time dependent signal status results for malfunction 4

나타낸 것이다. 각 변수들의 잔차가 임계치 이하인 경우 ○으로 표시하고, 임계치를 넘을 경우 +로 표시하였다.

고장의 종류와 변수에 따라 임계치를 동시에 넘거나 순차적으로 넘어서는 특징이 나타남을 확인하였다.

#### 2.4.3 고장 패턴 추출 및 고찰

고장 데이터 분석결과에서 각 고장마다 이상변수의 조합과 이상 신호의 검출 시점이 모두 다른 점을 근거로 하여 각 고장의 패턴을 추출하였다. Table 3은 고장 패턴의 추출 결과이다. 각각의 고장에서 이상이 나타나는 변수의 번호를 모두 표기했고, 이상 검출 시점이 같을 때는 하나의 박스 안에 넣고 순차적일 때는 화살표로 표시하여 그 순서를 나타냈다.

Table 3. Failure patterns for six malfunctions

No.	Failure Pattern
1	$\boxed{605} \rightarrow \boxed{604} \rightarrow \boxed{405, 406, 407, 603} \rightarrow \boxed{464} \rightarrow \boxed{465}$
2	$\boxed{162, 165, 166, 167, 168, 173, 174} \rightarrow \boxed{104} \rightarrow \boxed{191} \rightarrow \boxed{175} \rightarrow \boxed{34, 41} \rightarrow \boxed{190} \rightarrow \boxed{244} \rightarrow \boxed{178}$
3	$\boxed{344, 347} \rightarrow \boxed{162, 166, 167, 168, 173, 174, 355} \rightarrow \boxed{165} \rightarrow \boxed{322} \rightarrow \boxed{321} \rightarrow \boxed{34, 41, 104, 356} \rightarrow \boxed{341} \rightarrow \boxed{350}$
4	$\boxed{603} \rightarrow \boxed{604}$
5	$\boxed{105}$
6	$\boxed{59}$

6개의 고장에서 추출된 고장의 패턴이 모두 다르기 때문에 이상이 나타나는 변수의 조합을 비교하는 것으로 각각의 고장의 판별 및 분류가 가능하고, 2개 이상의 변수가 순차적으로 나타나는 1, 2, 3번 고장의 경우에는 고장 패턴을 활용하여 고장을 초, 중, 말기 등으로 단계적인 판별도 가능한 것을 확인하였다.

### 3. 결 론

본 논문에서는 원전에서 발생하는 여러 유형의 고장을 조기에 검출 및 식별하기 위해 AAKR을 이용해 고장 패턴을 추출하였다. 이를 수행하기 위해 필요한 모든 원전 데이터는 원전 시뮬레이터로부터 취득하였다.

AAKR을 적용하여 추정치와 측정치 사이의 잔차를 구하고 이를 분석하여 이상 변수의 조합과 이상 감지 시점으로 6가지 고장의 패턴을 추출하였다. 각 고장마다 고유의 패턴을 갖는 것을 확인하였고, 일부 고장에 대해서는 고장의 초, 중, 말기와 같은 상태의 판별 가능성도 확인하였다.

향후, 추출된 고장 패턴을 패턴 인식 알고리즘을 적용하면 원전의 신호를 감시하여 고장의 감지 및 식별이 가능할 것으로 예상된다.

### 후 기

본 연구는 산업통상자원부(MOTIE)와 한국에너지기술평가원(KETEP)의 지원을 받아 수행한 연구 과제입니다. (No. 20141520400090)

### 참고문헌

(1) Chan, A. M. C. and Ahluwalia, A. K., 1992,

- “Feedwater Flow Measurement in U.S. Nuclear Power Generation Stations,” EPRI.
- (2) Bond, L. J., Jarrel, D. B. and Gilbert, R. W., 2000, “On-Line Intelligent Self-Diagnostic Monitoring for Next Generation Nuclear Power Plants”, NPIC&HMIT, Washington DC, 1~10.
  - (3) Rasmussen, B. P., 2003, “Prediction Interval Estimation Techniques for Empirical Modeling Strategies and their Applications to Signal Validation Tasks”, *Doctoral thesis of University of Tennessee*, pp. 49-311.
  - (4) Kauermann, G., Marlene M. and Raymond, J. C., 1998, “The Efficiency of Bias-corrected Estimator for Nonparametric Kernel Estimation Based on Local Estimating Equations,” *Statistics and Probability Letters*, Vol. 37, pp. 41-47.
  - (5) Wand and Jones, 1997, *Kernel Smoothing, Monographs on Statistics and Applied Probability*, Chapman & Hall.
  - (6) Hines, J. W., Garvey, D. R., Seibert R. and Usynin, A., 2008, “Technical Review of On-Line Monitoring Techniques for Performance Assessment Volume 2 : Theoretical Issues”, *NUREG/CR-6895* Vol. 2, pp.23-51.
  - (7) An, S. H., 2010, “A Study on Online Monitoring System Developement using Empirical Models”, *Doctoral Thesis of KAIST*, pp. 29-39.
  - (8) Baraldi, P., Canesi, R., Zio, E. Seraoui, R. and Chevalier, R., 2011, “Signal Grouping for Condition Monitoring of Nuclear Power Plant Components”, *Advances in Safety, Reliability and Risk Management: ESREL*, France, pp.1-13.
  - (9) Yu, C. and Su, B., 2006, “Eliminating False Alarms Caused by Fault Propagation in Signal Validation by Sub-grouping”, *Prog. in Nucl. Energy*, Vol. 48, pp.317-379.